

Laboratorio #1 | Reporte escrito


Análisis

¿La curva de Zipf del corpus se parece a la curva teórica vista en clase?

Sí se parece bastante ya que el tramo medio de rangos la curva del corpus real corre casi pegada a la curva teórica k/rango . Las diferencias más notorias se ven en los dos extremos.

Por ejemplo, en la parte de las palabras más frecuentes la curva queda un poco por debajo de la teórica, y en las palabras más raras (rango alto) cae más rápido de lo que predice la teoría.

Esto pasa porque la ley de Zipf es un modelo idealizado, y en un corpus real de tamaño limitado como este (1138 documentos después de limpiar) hay palabras muy específicas que solo aparecen una o dos veces, entonces la cola se corta antes.



¿Cuánto se redujo el vocabulario en cada paso de normalización? ¿Cuál tuvo mayor impacto?

Se partió de 39,017 tipos después de tokenizar. Pasar a minúsculas redujo el vocabulario a 36,178 tipos quitar puntuación bajó muy poco más, a 36,142 tipos.

Por otro lado, quitar stopwords casi no cambió los tipos pero sí redujo muchísimo los tokens, de 598,368 a 318,949, porque las stopwords se repiten muchísimas veces en el texto aunque sean pocas palabras distintas.

El paso que más redujo el vocabulario fue la lematización, que dejó 28,801 tipos, un 26.18% menos que el original, porque agrupa todas las variantes de una palabra (plural, singular, conjugaciones) en una sola forma de diccionario.

¿Encontró algún caso donde quitar stopwords haya afectado el significado de una noticia?

Sí al revisar el pipeline se nota que se pierden palabras como no, sin, poco, que son justamente las que cambian el sentido de una oración.

Por ejemplo, una frase como "el mercado no creció" se queda como "mercado creció" después de quitar stopwords, y eso cambia un poco más el significado de lo que se está tratando de decir. Este es uno de los riesgos más grandes que puede pasar en este paso del pipeline cuando se aplica sin cuidado.

¿Qué desafíos propios del español encontró realmente en el corpus?

Ya que el español tiene mucha variación en la forma de escribir las palabras (por ejemplo, el género, número, conjugaciones de verbos es bastante completicado), por ende la lematización fue el paso que más redujo el vocabulario.

También siento que en las partes donde hay tildes y signos como “¿” y “¡” que hay que manejar aparte de la puntuación en inglés porque en ese idioma no se utilizan esos signos.

Otra cosa que también me costó un poco fue que hay algunas palabras que funcionan distinto según el contexto (más que todo en este caso que utiliza palabras financieras) del corpus, como puede ser con “tasa” o “mercado”, que en otro contexto significarían otra cosa, y el lematizador o el tokenizador no siempre distingue eso bien.

Si tuviera que entrenar un modelo de lenguaje con este corpus, ¿normalizaría de la misma forma? Justifique.

No, no de la misma forma pero sí con la misma lógica. Este pipeline (minúsculas, sin puntuación, sin stopwords, lematizado) es útil para tareas más “normales” o sencillas como puede ser la clasificación de texto con palabras o TF-IDF, porque reduce el ruido y el tamaño del vocabulario.

Pero si el objetivo fuera entrenar un modelo de lenguaje tipo transformer, no le quitaría las stopwords ni lo lematizaría, porque esos modelos aprenden mejor con el texto lo más natural posible, incluyendo mayúsculas, puntuación y toda la morfología, y usan tokenización por subpalabras en vez de tokenización por palabra completa como se hizo aquí en este caso con el laboratorio.

Link del repositorio:

<https://github.com/luispegr25/NLP>