

Laboratorio #4 - Modelos Lineales

Reporte escrito

1. Construcción del clasificador de regresión logística

Se entrenaron dos modelos de regresión logística usando exactamente las mismas particiones de entrenamiento, validación y prueba del Laboratorio #3: uno con Bolsa de Palabras (BoW) y otro con TF-IDF.


$z = w \cdot x + b$ es el puntaje que el modelo calcula para cada categoría. x representa el documento vectorizado, w son los pesos aprendidos para las palabras y b es el intercepto. Un peso positivo favorece una categoría y uno negativo la aleja. En clasificación binaria, la sigmoide transforma z en una probabilidad entre 0.

2. Entrenamiento, métricas y matrices de confusión

En validación, regresión logística con BoW obtuvo accuracy 0.8655, F1 macro 0.83 y F1 ponderado 0.86. Con TF-IDF obtuvo accuracy 0.8421, F1 macro 0.72 y F1 ponderado 0.83. En prueba, BoW mejoró ligeramente a accuracy 0.8713, F1 macro 0.8534 y F1 ponderado 0.8732; TF-IDF bajó a accuracy 0.7953, F1 macro 0.7048 y F1 ponderado 0.7779. Por lo tanto, BoW fue la mejor representación para regresión logística en este corpus.

Sí se puede decir que hay overfitting. Ya que el BoW alcanzó 1.0000 de accuracy en entrenamiento, pero 0.8655 en validación y 0.8713 en prueba. TF-IDF obtuvo 0.9623 en entrenamiento, 0.8421 en validación y 0.7953 en prueba. Aun así, BoW generaliza mejor porque validación y prueba son muy parecidas. Una posible explicación es que la frecuencia absoluta de ciertas palabras contiene información útil para separar estas categorías, mientras que TF-IDF reduce el peso de términos frecuentes que aquí todavía pueden ser discriminativos.

Matrices de confusión en prueba (orden de clases: Alianzas, Innovacion, Macroeconomia, Otra, Regulaciones, Reputacion, Sostenibilidad).



3. Interpretación de pesos

Para el mejor modelo, RL con BoW, se revisaron 15 pesos positivos y 15 negativos de Alianzas, Innovación y Macroeconomía. Los resultados sí tienen sentido en general. En Alianzas, el mayor peso positivo fue alianza (1.0131) y también aparecen acuerdo, aliado, programa y compañía.

En Innovación destacan tecnología, agile, design, emprendimiento, pago, teléfono y seguridad. En Macroeconomía aparecen inflación (0.5009), precio, aumento, economista, ipc, economía y crecimiento. Los pesos negativos también ayudan a separar clases; por ejemplo, digital, empresa y usuario son negativos para Macroeconomía.

Al comparar con Naive Bayes, las palabras principales no coinciden por completo. Naive Bayes mostraba varios términos muy frecuentes y poco específicos, como poder, país, empresa, banco o año, porque estima $P(w_i|c)$ por palabra.

Regresión logística aprende los pesos en grupo o en conjunto, por lo que puede dar más importancia a términos que realmente separan una categoría y asignar pesos negativos a palabras frecuentes que no ayudan a distinguirla.

4. Comparación con Naive Bayes y regularización

Modelo	Representación	Accuracy	F1 macro	F1 ponderado	Tiempo (s)
Naive Bayes	BoW	0.818713	0.742496	0.808096	0.0023
Naive Bayes	TF-IDF	0.555556	0.336178	0.460059	0.0020
Regresión Logística	BoW	0.871345	0.853434	0.873186	0.3314
Regresión Logística	TF-IDF	0.795322	0.704799	0.777896	0.1834

El mejor resultado fue Regresión Logística con BoW. Frente a Naive Bayes con BoW, el accuracy mejoró de 0.8187 a 0.8713 y el F1 macro de 0.7425 a 0.8534.

Aunque la mejora en accuracy no es enorme, el aumento en F1 macro muestra que la regresión logística clasificó mejor las distintas categorías. Naive Bayes fue mucho más rápido, pero la regresión logística obtuvo mejores resultados al aprender los pesos de las palabras de forma conjunta.

La regresión logística utilizó regularización L2 con $C = 1.0$, lo que ayuda a controlar pesos demasiado grandes y reducir overfitting. También se probó con $C = 0.01, 0.1, 1$ y 10 para comparar su efecto en el desempeño.

5. Análisis de errores

La confusión más frecuente fue entre Otra y Sostenibilidad, con 4 documentos mal clasificados. Los documentos 0, 427, 697 y 989 contienen términos como desarrollo sostenible, ODS, acuerdos de París y financiamiento sostenible, por lo que es comprensible que el modelo los asociara con Sostenibilidad.

Naive Bayes también falló exactamente en esos mismos cuatro documentos. Esto indica que el problema no depende únicamente del modelo, sino también de que estas noticias tienen contenido bastante ambiguo entre ambas categorías.

Naive Bayes considera la evidencia de las palabras por separado, mientras que la regresión logística aprende sus pesos conjuntamente. Aun así, en estos casos el contenido relacionado con sostenibilidad fue suficiente para que ambos modelos cometieran el mismo error.

6. Análisis

1. Los dos modelos utilizan las palabras del documento para decidir a qué categoría pertenece, pero aprenden de forma diferente. Naive Bayes calcula qué tan relacionada está cada palabra con una categoría de forma individual, mientras que la regresión logística aprende todos los pesos al mismo tiempo.

En los resultados, Regresión Logística con BoW tuvo mejor desempeño que Naive Bayes con BoW. El accuracy fue de 0.8713 frente a 0.8187 y el F1 macro fue de 0.8534 frente a 0.7425. Esto muestra que la regresión logística logró separar mejor las categorías en este corpus.

2. Sí se puede observar esta diferencia en los pesos obtenidos. Por ejemplo, en la categoría Alianzas, Naive Bayes muestra palabras bastante generales como poder, país, millón, empresa y año.

Por otro lado, la regresión logística le da más importancia a palabras más relacionadas directamente con la categoría, como alianza, acuerdo y aliado. Incluso palabras como

bbva pueden recibir un peso negativo, ya que aparecer mucho en el corpus no significa necesariamente que ayuden a identificar esa categoría.

En el caso de Otra y Sostenibilidad, ambos modelos fallaron en los mismos cuatro documentos. Esto muestra que, aunque la regresión logística puede manejar mejor la combinación de palabras, sigue teniendo dificultades cuando el contenido de un documento es muy parecido al de otra categoría.

3. Preferiría usar Naive Bayes cuando el corpus sea pequeño, cuando se necesite entrenar muy rápido o cuando el modelo tenga que reentrenarse constantemente. En este laboratorio, por ejemplo, su tiempo de entrenamiento fue de aproximadamente 0.002 segundos.

Usaría regresión logística cuando me interese más obtener un mejor desempeño y analizar qué palabras están ayudando o perjudicando a cada categoría. En este caso escogería regresión logística porque tuvo mejores resultados generales.

4. La línea base consiste en predecir siempre la categoría más frecuente, que en este caso fue Macroeconomía. Esta estrategia obtuvo un accuracy de 0.2807.

Naive Bayes con BoW obtuvo 0.8187, mientras que Regresión Logística con BoW obtuvo 0.8713. Esto significa que ambos modelos están muy por encima de la línea base y realmente están aprendiendo patrones dentro del texto, en lugar de simplemente aprovechar que una categoría aparece más veces que las demás.

5. Si el modelo se fuera a usar en producción, no tomaría la decisión únicamente basándome en accuracy. También revisaría el F1 macro, el tiempo que tarda en hacer predicciones, el tamaño del modelo, qué tan fácil es volver a entrenarlo y qué tan sencillo es interpretar sus pesos.

Para este caso mantendría Regresión Logística con BoW, porque fue el modelo con mejor desempeño y su tiempo de entrenamiento sigue siendo bastante bajo para un corpus de este tamaño. Solamente elegiría Naive Bayes si fuera mucho más importante entrenar el modelo extremadamente rápido o actualizarlo constantemente con datos nuevos.

Link para el github: <https://github.com/luispegr25/NLP>