

Laboratorio 6

Identificación de las novelas

El laboratorio trabajó con tres novelas del dataset Gutenberg Classic Novels Text Dataset. Los textos corresponden a *Pride and Prejudice* de Jane Austen, publicada en 1813, *Frankenstein* de Mary Shelley, publicada en 1818, y *Dracula* de Bram Stoker, publicada en 1897. Las tres obras pertenecen a épocas distintas y eso permite comparar cómo se comportan herramientas de NLP entrenadas con inglés más contemporáneo frente a estilos y vocabulario más antiguos.

Libro	Autor	Año
Pride and Prejudice	Jane Austen	1813
Frankenstein	Mary Shelley	1818
Dracula	Bram Stoker	1897

Sección 1 Preparación de la muestra de trabajo

Después de limpiar y segmentar cada novela se contaron las oraciones y tokens del texto completo. *Dracula* fue la novela más extensa con 8,527 oraciones y 190,147 tokens. *Pride and Prejudice* tuvo 5,943 oraciones y 144,296 tokens, mientras que *Frankenstein* fue la más corta con 3,316 oraciones y 85,728 tokens. Para trabajar con una cantidad de texto que se pudiera revisar manualmente se seleccionaron 100 oraciones aleatorias de cada libro usando una semilla fija.

Aunque las tres muestras tuvieron la misma cantidad de oraciones, *Frankenstein* terminó con más tokens. Esto indica que las oraciones seleccionadas de esa novela fueron, en promedio, un poco más largas que las de las otras dos muestras.

Sección 2 Etiquetado gramatical

El etiquetado POS mostró distribuciones bastante parecidas entre las tres novelas en varias categorías. Los verbos representaron alrededor del 13 por ciento de los tokens en los tres libros y los pronombres estuvieron cerca del 16 por ciento. Una diferencia más visible apareció en los sustantivos. *Frankenstein* tuvo 18.11 por ciento, mientras que *Dracula* tuvo 14.93 por ciento y *Pride and Prejudice* 14.43 por ciento.

Categoría	Pride and Prejudice	Frankenstein	Dracula
NOUN	14.43	18.11	14.93
VERB	13.13	13.30	13.19
ADJ	5.58	7.25	7.33
PRON	16.07	15.90	16.45
PROPN	5.29	2.02	3.21

Pride and Prejudice tuvo la mayor proporción de nombres propios con 5.29 por ciento. Esto puede deberse a que en la muestra aparecen muchos personajes mencionados directamente por nombre. Frankenstein y Dracula mostraron una proporción mayor de adjetivos. Las diferencias existen, pero la estructura general de las tres muestras sigue siendo bastante parecida.

También se encontraron palabras que recibieron etiquetas diferentes según el contexto. Entre ellas aparecieron the, to y a. El caso de to muestra bien la ambigüedad porque puede funcionar como PART cuando introduce un infinitivo y como ADP cuando funciona como preposición. Otros cambios no parecieron ser ambigüedad real. Por ejemplo, el modelo clasificó a como pronombre en un caso y asignó una etiqueta poco común a the. Esto parece estar más relacionado con errores del tagger.

Sección 3 Tagsets y anotación

Para comparar tagsets se utilizó Pride and Prejudice. El tagset universal da categorías generales mientras que Penn Treebank agrega información más específica. Por ejemplo, She aparece como PRON en el tagset universal y como PRP en Penn Treebank. Is aparece como AUX en el universal y como VBZ en Penn Treebank. También se observó que fifteen pasa de NUM a CD y handsome de ADJ a JJ. Esto muestra que Penn Treebank permite describir con más detalle la función gramatical de cada token.

En la anotación manual de cinco oraciones se compararon 47 tokens. Hubo 46 coincidencias con el tagger automático, lo que produjo un 97.87 por ciento de coincidencia. El único desacuerdo fue la palabra about en la expresión about fifteen or sixteen. Manualmente se había colocado IN, mientras que el modelo asignó RB. Al revisar el contexto, RB tiene sentido porque about significa aproximadamente y modifica

la cantidad. Por eso este caso parece ser más una diferencia de criterio en la anotación manual que un error claro del modelo.

Sección 4 Reconocimiento de entidades nombradas

Para NER se analizaron las primeras 250 oraciones válidas de cada novela. *Pride and Prejudice* tuvo 234 entidades detectadas, *Frankenstein* 126 y *Dracula* 151. La diferencia más marcada apareció en PERSON. *Pride and Prejudice* tuvo 133 entidades de este tipo, mientras que *Frankenstein* tuvo 18 y *Dracula* 24.

Libro	PERSON	GPE	LOC	ORG	Total	Entidades por 100 tokens
<i>Pride and Prejudice</i>	133	11	0	16	234	4.13
<i>Frankenstein</i>	18	19	4	1	126	1.79
<i>Dracula</i>	24	22	11	21	151	2.06

Pride and Prejudice tuvo la mayor densidad con 4.13 entidades por cada 100 tokens. *Dracula* quedó en segundo lugar con 2.06 y *Frankenstein* tuvo 1.79. En *Pride and Prejudice* aparecen correctamente nombres como Bingley, Bennet, Darcy, Jane y Elizabeth, además de lugares como Netherfield y London. También hubo errores como Charlotte y Lydia clasificadas como lugares.

En *Frankenstein* se observaron confusiones con Beaufort y otros nombres, mientras que en *Dracula* aparecieron errores como Danube clasificado como persona. Esto demuestra que los conteos sirven para comparar los textos, pero no todas las entidades detectadas deben tomarse como correctas.

Sección 5 Esquema BIO

El esquema BIO se construyó sobre cinco oraciones consecutivas y se revisaron las entidades antes de asignar las etiquetas. Jane, Bingley y Darcy quedaron como entidades PERSON. Derbyshire fue corregido a GPE porque el modelo lo había clasificado como ORG.

También se amplió Bennet a Mr. Bennet para conservar la entidad completa. A partir de estas correcciones se asignó B al primer token de cada entidad, I a los tokens que continuaban la misma entidad y O a los tokens que quedaban fuera.

Sección 6 Evaluación de entidades

Para crear el gold standard se utilizaron 20 oraciones de cada novela y se anotaron manualmente entidades de los tipos PERSON, GPE, LOC, ORG y NORP. Luego se compararon estas anotaciones con las predicciones del modelo a nivel de token y a nivel de entidad completa.

Libro	Nivel	Precisión	Recall	F1
Pride and Prejudice	Token	0.750	0.562	0.643
Pride and Prejudice	Entidad completa	0.700	0.700	0.700
Frankenstein	Token	0.647	0.647	0.647
Frankenstein	Entidad completa	0.625	0.625	0.625
Dracula	Token	0.917	0.846	0.880
Dracula	Entidad completa	0.875	0.875	0.875

Dracula obtuvo los mejores resultados en las dos formas de evaluación. Frankenstein quedó por debajo y Pride and Prejudice tuvo un comportamiento diferente porque su F1 por entidad completa fue mayor que su F1 por token. Por lo tanto, la evaluación por token no fue más optimista en los tres casos. Parte de esta diferencia se explica porque las etiquetas BIO pueden generar varios desacuerdos cuando el modelo detecta solamente una parte de una entidad.

Los errores también fueron diferentes entre novelas. En Pride and Prejudice el modelo detectó Gardiner en lugar de Mr. and Mrs. Gardiner y Bennet en lugar de Mr. Bennet.

Además clasificó Derbyshire como ORG. En Frankenstein se observaron más confusiones de tipo, como Turk clasificado como PERSON, Felix como ORG y Leghorn como NORP.

Sección 7 Conclusiones comparativas

Las distribuciones POS y las entidades muestran diferencias de estilo entre los tres autores. Frankenstein tuvo una mayor proporción de sustantivos y, junto con Dracula, un porcentaje mayor de adjetivos. Pride and Prejudice tuvo más nombres propios y también la mayor densidad de entidades. Esto coincide con una muestra donde aparecen constantemente personajes identificados por nombre.

Dracula quedó en un punto intermedio en densidad y presentó una mezcla más variada de personas, lugares y organizaciones. Estas diferencias no describen por sí solas todo el estilo de cada autor, pero sí muestran patrones distintos dentro de las muestras analizadas.

La ambigüedad de POS se relaciona con los modelos de lenguaje n grama porque en ambos casos la predicción depende del contexto. Un tagger no puede decidir correctamente la categoría de una palabra mirando solamente el token aislado.

De manera parecida, un modelo n grama estima qué palabra es más probable que siga usando las palabras anteriores como contexto. En los dos problemas una misma unidad puede tener resultados diferentes dependiendo de lo que aparece alrededor.

La diferencia de época también ayuda a explicar varios errores. Los modelos utilizados fueron entrenados con inglés más contemporáneo, mientras que las novelas contienen ortografía, nombres, expresiones y construcciones de los siglos diecinueve y finales del diecinueve.

Formas como to morrow y To night pueden causar problemas de tokenización y etiquetado. En NER también aparecen nombres y lugares que el modelo confunde con otras categorías. Esto se relaciona con el problema de vocabulario fuera de dominio porque el modelo encuentra palabras y usos que no se parecen tanto a los datos con los que fue entrenado.

Si se tuviera que reportar el desempeño de un sistema real de NER a un cliente, usaría como número principal la evaluación por entidad completa. Para una aplicación real normalmente importa que el sistema encuentre toda la entidad y que también asigne el tipo correcto. Detectar solamente una parte del nombre puede no ser suficiente.

LINK AL REPOSITORIO: [HTTPS://GITHUB.COM/LUISPEGR25/NLP](https://github.com/LUISPEGR25/NLP)